

# Detecção e Classificação de Doenças da Batata

1<sup>st</sup> Jeffri Erwin Murrugarra Llerena

Nro Usp (10655837)

São Carlos, Brasil

ju.jeffri.v@gmail.com

**Resumo**—O objetivo deste projeto é detectar áreas afetadas por praga em uma folha de batata e depois classificar a folha da batata entre 3 classes (folha em bom estado, folha afetada por *Alternaria solani*, folha afetada por *Phytophthora infestans*).

## I. DESCRIÇÃO DO PROBLEMA

Cada ano o mercado de produção de batata sofre perda devido a infestação de pragas, uma estimativa da Organização das Nações Unidas para Alimentação e Agricultura (FAO), do 20% até 40% de perda na produção. Se essas pragas forem detectadas a tempo, podem ser tomadas medidas preventivas para mitigar as perdas econômicas e de produção. Tradicionalmente, a detecção dessas pragas é feita por um especialista humano, mas nem todos os produtores podem cobrir as despesas. Assim, o objetivo deste projeto é a detecção e classificação de doenças da batata causadas por pragas.

## II. DESCRIÇÃO DAS IMAGENES

O tipo de imagens a ser utilizado são separados em 3 grupos: Imagens de folhas de batata em boas condições, Imagens de folhas de batata afetadas por *Phytophthora infestans* (pragas avançado), imagens de folhas de batata afetadas por *Alternaria solani* (praga leve), as imagens foram obtidas de PlantVillage-Dataset link aqui, as imagens estão em formato RGB, com dimensões de 256x256.



Figura 1. Tipos de folha

## III. MÉTODO PROPOSTO

Para cumprir o objetivo dividimos o problema em 3 partes: segmentação(segmentação com o fundo, segmentação das áreas verdes), extração de características(descriptores de cores e texturas) e classificação (SVM, KNN)



Figura 2. Amostragem de folha de batata

### A. Segmentação

Para a segmentação com o fundo, foi trabalhado no espaço de cor HSV(com o canal de saturação). Uma vez obtida a imagen de saturação foi aplicado o algoritmo Otsu para obter o valor threshold indicado, com o threshold obtido foi binarizada a imagem. Apos isso, aplicaron-se operações morfológicas como fechamento com uma matriz preenchida de uns, com dimensões de 18x18. Depois disso se preencheu os buracos dentro da imagen obtida(A ideia é fazer dilatações em uma matriz preenchida de zeros só que considerando um padding de uns em torno a matriz, até que tope com a imagen binarizada obtida, el complemento de isso vai a ser o resultado).



Figura 3. Aplicação da imagen binarizada do fundo

Para a segmentação das áreas verdes, trabalho-se no espaço de cor  $l^*a^*b^*$ (com o canal de  $a^*$ ), para a binarização se tomo un thresh de 0 dado que de acordo com a teoria, cuando  $a^*$  e menor 0 representam cores perto de verde, apos isso se aplicaron operações morfológicas como fechamento y depois erosion a fim de suavizar as bordas.



Figura 4. Aplicação da imagen binarizada das áreas verdes

Para a segmentação final, foi combinado as 2 imagens binarizadas obtidas nos passos anteriores. Uma vez obtida uma única imagem binarizada foi aplicada à imagem original.



Figura 5. Aplicação da imagen binarizada final

### B. Extração de características

Os três elementos fundamentais usados na interpretação das imagens são espectral, textural e contextual características. Neste trabalho, extraímos 9 características (cores e textural) de todas as imagens das folhas do conjunto de dados. Do Histograma de cor foi extraído média, desvio padrão, skewness, kurtosis e da matriz de co-concorrência foi extraído contraste, correlação, energia, homogeneidade e entropia

Tabela I  
FÓRMULAS USADAS

CARACTERÍSTICA	FORMULAÇÃO MATEMÁTICA
Contraste	$\sum_i \sum_j (i - j)^2 g_{ij}$
Correlação	$\frac{\sum_i \sum_j (ij) g_{ij} - \mu_x \mu_y}{\sigma_x \sigma_y}$
Energia	$\sum_i \sum_j g_{ij}^2$
Homogeneidade	$\sum_i \sum_j \frac{1}{1 + (i - j)^2} g_{ij}$
Média	$\sum_{i=0}^{L-1} g(i) P(g(i))$
Desvio Padrão	$\sqrt{\sum_{i=0}^{L-1} (g(i) - M)^2 P(g(i))}$
Skewness	$\frac{1}{s^3} \sum_{i=0}^{L-1} (g(i) - M)^3 P(g(i))$
Entropia	$-\sum_{i=0}^{L-1} P(g(i)) \log_2 P(g(i))$
Kurtosis	$\frac{1}{s^4} \sum_{i=0}^{L-1} (g(i) - M)^4 P(g(i))$

### C. Classificação

Na etapa de classificação foi utilizado o pacote de scikit learn, para testar diferentes algoritmos de classificação.

## IV. RESULTADOS E DISCUSSÃO

Foram testados 3 algoritmos de classificação (KNN, SVM, MLP). Nosso banco de dados experimental consiste de 152 imagens de folhas saudáveis e 304 imagens de folhas afetadas por praga.

Durante o experimento, o banco de dados foi dividido em dois conjuntos: o conjunto de treinamento contendo 319 imagens (70%) e o conjunto de testes contendo 137 imagens (30%). Para fins de classificação, foram testados 3 classificadores com base nos algoritmos de SVM, KNN e MLP. Foi obtida uma accuracy de 99.27% no conjunto de teste e de 99.05% no conjunto de treinamento com SVM, com KNN, com MLP. Outros dados como precisão, recall, medida f1 também foram obtidos.

Tabela II  
MEDIDAS DE DESEMPENHO DA CLASSIFICAÇÃO COM SVM

Aula	Precisão (%)	Memória (%)	F1-medida (%)
Batata praga tardia	100%	100%	100%
Batata praga leve	100%	97.9%	98.4%
Batata saudável	97.5%	100%	98.7%
Média	99.1 %	99.3 %	99.2 %




Figura 6. Matriz de confusão (SVM)

Tabela III  
MEDIDAS DE DESEMPENHO DA CLASSIFICAÇÃO COM KNN

Aula	Precisão (%)	Memória (%)	F1-medida (%)
Batata praga tardia	100 %	100 %	100 %
Batata praga leve	97.7 %	93.6 %	95.6 %
Batata saudável	93 %	97.5 %	95.6 %
Média	96.9 %	97 %	95.2 %

## V. CONCLUSÕES

As doenças da folha de batata foram identificadas obtendo um bom desempenho de acerto com os diferentes classificadores, obtendo o melhor resultado do classificador treinado com SVM.




Figura 7. Matriz de confusão (KNN)

Tabela IV  
MEDIDAS DE DESEMPENHO DA CLASSIFICAÇÃO COM MLP

Aula	Precisão (%)	Memória (%)	F1-medida (%)
Batata plaga tardia	100%	100%	100%
Batata plaga leve	93.7 %	91.8 %	92.7 %
Batata saudavel	91.4 %	93.4 %	92.4 %
Média	95 %	95 %	95%




Figura 8. Matriz de confusão (MLP)